

Erroarea pătratică medie (mean square error)

Def: Fie X_1, X_2, \dots, X_n din Θ , și $\hat{\theta}_n$ estimator. Definim
eroarea pătratică:

$$MSE_{\theta}(\hat{\theta}_n) = E_{\theta}[(\hat{\theta}_n - \theta)^2]$$

Înținem că estimatorul $\hat{\theta}_1$ este mai bun decât estimatorul $\hat{\theta}_2$ (în sensul MSE) dacă $MSE_{\theta}(\hat{\theta}_1) < MSE_{\theta}(\hat{\theta}_2)$

① Avem că $MSE_{\theta}(\hat{\theta}) = Var_{\theta}(\hat{\theta}) + b_{\theta}(\hat{\theta})^2$

În particular dacă $\hat{\theta}$ nedreptățat pt θ , atunci

$$MSE_{\theta}(\hat{\theta}) = Var_{\theta}(\hat{\theta})$$

Obs: În general vrem să găsim estimatori pt. care MSE este cât mai mică.

Ex: $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ și scopul este să estimăm varianța σ^2 .

Avem statistica $T_n = \sum_{i=1}^n (X_i - \bar{X}_n)^2$ și căutăm un estimator de forma $\hat{\sigma}_a^2 = a T_n$, $a = a(n) > 0$.

Până acum am văzut $a = \frac{1}{n} \rightarrow$ varianța empirică V_n
 $a = \frac{1}{n-1} \rightarrow$ varianța eșantionului

Vicior să determinăm a pentru care $MSE_{\sigma^2}(\hat{\sigma}_a^2)$ minimă

$$MSE_{\sigma^2}(\hat{\sigma}_a^2) = Var_{\sigma^2}(\hat{\sigma}_a^2) + b_{\sigma^2}(\hat{\sigma}_a^2)^2$$

Reamintim în cazul populației normale

$$\frac{(n-1)S_n^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{\sigma^2} \sim \chi^2(n-1)$$

$$\Rightarrow \frac{T_n}{\sigma^2} \sim \chi^2(n-1)$$

$$\text{stim} \begin{cases} E[X^2(\nu)] = \nu \\ \text{Var}(X^2(\nu)) = 2\nu \end{cases}$$

$$E_{\sqrt{2}}\left(\frac{T_n}{\sqrt{2}}\right) = n-1 \Rightarrow E_{\sqrt{2}}[T_n] = (n-1)\sqrt{2}^2$$

$$\text{Var}_{\sqrt{2}}\left(\frac{T_n}{\sqrt{2}}\right) = 2(n-1) \Rightarrow \text{Var}_{\sqrt{2}}(T_n) = 2(n-1)\sqrt{2}^4$$

Astfel

$$\begin{aligned} \text{MSE}_{\sqrt{2}}(\hat{\nu a}^2) &= \text{Var}_{\sqrt{2}}(\hat{\nu a}^2) + b_{\sqrt{2}}^2(aT_n)^2 = \\ &= a^2 \text{Var}_{\sqrt{2}}(T_n) + [E_{\sqrt{2}}(aT_n) - \sqrt{2}^2]^2 = \\ &= 2a^2(n-1)\sqrt{2}^4 + [a(n-1)\sqrt{2}^2 - \sqrt{2}^2]^2 = \\ &= \sqrt{2}^4 [2a^2(n-1) + (a(n-1) - 1)^2] \end{aligned}$$

Derivând după a obținem

$$\begin{aligned} \frac{d}{da} \text{MSE}_{\sqrt{2}}(\hat{\nu a}^2) &= \sqrt{2}^4 [4a(n-1) + 2(a(n-1) - 1)(n-1)] \\ &= 2\sqrt{2}^4 (n-1) [2a + a(n-1) - 1] \end{aligned}$$

$$\frac{d}{da} \text{MSE}_{\sqrt{2}}(\hat{\nu a}^2) = 0 \Leftrightarrow 2a + a(n-1) - 1 = 0 \Rightarrow a = 1/n+1$$

Pînă urmare printre estimatorii lui $\sqrt{2}^2$ de forma $a \sum_{i=1}^n (X_i - \bar{X}_n)^2$, estimatorul cu MSE cea mai mică

$$\text{este } \frac{1}{n+1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Estimatorul $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ plătește un pret pentru a

fi nedepășat.

① Dacă $\text{MSE}_{\hat{\theta}_n}(\hat{\theta}_n) \rightarrow 0$ pt. $n \rightarrow \infty$, atunci $\hat{\theta}_n$ e un estimator consistent pentru θ

~~Ex.~~ Compararea a 2 estimatori nedepășati după MSE

Fie $X_1, X_2, \dots, X_n \sim \text{Pois}(\theta)$ și $\hat{\theta}_1 = \bar{X}_n$ și $\hat{\theta}_2 = S_n^2$

doi estimatori nedepășati pentru θ . Vrem să determinăm care este mai bun din punctul de vedere al MSE.

$$\begin{array}{cc} MSE_{\theta}(\hat{\theta}_1) & (?) MSE_{\theta}(\hat{\theta}_2) \\ \text{"} & \text{"} \\ Var_{\theta}(\hat{\theta}_1) & Var_{\theta}(\hat{\theta}_2) \end{array}$$

Metode de construcție a estimatorilor

1) Metoda momentelor:

- sfârșitul sec. \bar{X} , începutul sec. \bar{X} (Karl Pearson)

Fie X_1, X_2, \dots, X_n un eșantion de volum n dintr-o populație de densitate f_{θ} , $\theta \in \Theta \subseteq \mathbb{R}^k$, $\theta = (\theta_1, \theta_2, \dots, \theta_k)$

Dacă $X \sim f_{\theta}$, atunci momentele de ordin j , $1 \leq j \leq k$

$$\text{sunt } E[X^j] = \int_{-\infty}^{+\infty} x^j f_{\theta}(x) dx, j \in \{1, 2, \dots, k\}$$

În general

$$E[X^1] = g_1(\theta_1, \dots, \theta_k)$$

...

$$E[X^k] = g_k(\theta_1, \dots, \theta_k)$$

Metoda momentelor presupune rezolvarea sistemului de ecuații:

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = g_1(\theta_1, \dots, \theta_k) \\ \dots \\ \frac{1}{n} \sum_{i=1}^n X_i^k = g_k(\theta_1, \dots, \theta_k) \end{cases}$$

Soluția este estimatorul obținut prin metoda momentelor.

Exp: $X_1, X_2, \dots, X_n \sim \text{Exp}(\lambda)$, $\theta = \lambda \in (0, +\infty)$

Turn $\theta \in \mathbb{R} \Rightarrow k=1$

Momentul empiric de ordin 1 = Momentul teoretic de ordin 1.

$$\bar{X}_n = \mathbb{E}_\lambda[X_1] = \frac{1}{\lambda} \Rightarrow \boxed{\bar{X}_n = \frac{1}{\lambda_n}}$$

Exp: Fie $X_1 = 0,42$, $X_2 = 0,10$, $X_3 = 0,65$, $X_4 = 0,23$ un eșantion de volum $n=4$ și populație

$$f_\theta(x) = \theta x^{\theta-1}, \quad 0 \leq x \leq 1$$

$$\theta \in (0, 1] \subseteq \mathbb{R} \Rightarrow k=1$$

Met. momentelor presupune rezolvarea:

$$\bar{X}_n = \mathbb{E}_\theta[X_1] = \int_{-\infty}^{+\infty} x f_\theta(x) dx = \int_0^1 x \theta x^{\theta-1} dx = \frac{\theta}{\theta+1}$$

$$\Rightarrow \bar{X}_n = \frac{\tilde{\theta}_n}{\tilde{\theta}_n + 1} \Rightarrow \boxed{\tilde{\theta}_n = \frac{\bar{X}_n}{1 - \bar{X}_n}} \quad \bar{X}_4 = 0,35$$

$$\tilde{\theta}_4 = \frac{0,35}{1 - 0,35} = 0,54$$

Exp: $X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2)$

În acest caz $\theta = (\theta_1, \theta_2) = (\mu, \sigma^2)$

$$\theta \in \Theta = \mathbb{R} \times (0, \infty) \subseteq \mathbb{R}^2, \quad k=2$$

Sistem cu 2 ecuații și 2 necunoscute

$$\begin{cases} \bar{X}_n = \mathbb{E}_\theta[X_1] \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \mathbb{E}_\theta[X_1^2] \end{cases}$$

$$\text{Dacă } X_1 \sim N(\mu, \sigma^2) \Rightarrow \mathbb{E}_\theta[X_1] = \mu \\ \mathbb{E}_\theta[X_1^2] = \sigma^2 + \mu^2$$

Sistemul devine

$$\begin{cases} \bar{x}_m = \mu \\ \frac{1}{n} \sum_{i=1}^n x_i^2 = \sigma^2 + \mu^2 \end{cases} \Rightarrow \begin{cases} \tilde{\mu}_m = \bar{x}_m \\ \tilde{\sigma}_m^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}_m^2 \end{cases}$$

$$\Rightarrow \begin{cases} \tilde{\mu}_m = \bar{x}_m \\ \tilde{\sigma}_m^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_m)^2 \end{cases}$$

Obs: Ce se întâmplă în cazul unei repartiții $Bl(n, p)$

$$\begin{cases} \bar{x}_m = kp \\ \frac{1}{n} \sum_{i=1}^n x_i^2 = kp(1-p) + k^2 p^2 \end{cases} \quad \begin{cases} p \in (0, 1) \\ k \in \mathbb{N} \end{cases}$$

2) Metoda verosimilității maxime (Maximum likelihood)

Fie $X_1, X_2, \dots, X_n \sim f_\theta(x)$, $\theta \in \Theta \subseteq \mathbb{R}^k$

Densitatea (masa) comună a (X_1, X_2, \dots, X_n) este

$$f_\theta(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i)$$

Def: Se numește funcție de verosimilitate asociată esenționului x_1, x_2, \dots, x_n funcția

$$L(\theta; x_1, x_2, \dots, x_n) = f_\theta(x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i)$$

și este văzută ca o funcție de θ

$$l(\theta; x_1, x_2, \dots, x_n) = \log L(\theta; x_1, \dots, x_n)$$

Obs: Uneori putem întâlni doar notația $L(\theta)$ și $l(\theta)$ sau $L(\theta/x)$ și $l(\theta/x)$, $x = (x_1, \dots, x_n)$

Obs: Funcția de verosimilitate nu este o densitate de probabilitate pentru θ

Obs: Dacă $L(\theta_1, x) > L(\theta_2, x)$ (echivalent cu)

$$l(\theta_1, x) > l(\theta_2, x)$$

atunci spunem că θ_1 este mai probabil decât θ_2 și
fi produs x_1, x_2, \dots, x_n

Cu alte cuvinte f_{θ_1} reprezintă un model mai
bun decât f_{θ_2} în ceea ce privește fixarea datelor
observate

Def: Fie $x_1, x_2, \dots, x_n \sim f_{\theta}(x)$, și $L(\theta/x)$, $l(\theta/x)$
sunt funcția de verosimilitate, respectiv log. fct. de verosi-
mitate

Numim estimator de verosimilitate maximă
(MLE) pentru θ

$$\hat{\theta}_n = \underset{\theta \in \Theta}{\operatorname{argmax}} L(\theta/x) = \underset{\theta \in \Theta}{\operatorname{argmax}} l(\theta/x)$$

$$\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$$

Obs: Dacă funcția de verosimilitate este diferen-
țiaabilă, atunci posibili candidați pentru estimatorul
MLE sunt soluțiile sistemului

$$\frac{\partial}{\partial \theta_i} L(\theta/x) = 0, \quad i = 1, \dots, k$$

Exp: $x_1, x_2, \dots, x_n \sim \text{Bernoulli}(\theta)$, $\theta \in (0, 1)$

$$L(\theta/x) = \prod_{i=1}^n f_{\theta}(x_i)$$

$$f_{\theta}(x) = \begin{cases} \theta, & x=1 \\ 1-\theta, & x=0 \end{cases} = \theta^x (1-\theta)^{1-x}$$

$$L(\theta/x) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i}$$

$$= \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i}$$

$$\text{Avem } l(\theta/x) = \log L(\theta/x) =$$

$$= \left(\sum_{i=1}^n x_i \right) \log \theta + \left(n - \sum_{i=1}^n x_i \right) \log(1-\theta)$$

Dacă $0 < \sum_{i=1}^n X_i < n$ atunci derivând

$$\frac{d}{d\theta} l(\theta/x) = \frac{\sum_{i=1}^n X_i}{\theta} - \left(n - \sum_{i=1}^n X_i\right) \frac{1}{1-\theta} = 0$$

$$\Leftrightarrow \frac{\sum_{i=1}^n x_i}{\theta} = \frac{1}{1-\theta} \left(n - \sum_{i=1}^n x_i\right)$$

$$\Leftrightarrow \frac{\bar{x}_n}{\theta} = \frac{1}{1-\theta} (1 - \bar{x}_n) \Rightarrow \hat{\theta}_n = \bar{x}_n$$

Dacă $\sum_{i=1}^n X_i = 0$ sau $\sum_{i=1}^n X_i = n$

$$l(\theta/x) = \begin{cases} n \log(1-\theta), & \sum_{i=1}^n X_i = 0 \\ n \log(\theta), & \sum_{i=1}^n X_i = n \end{cases}$$

și $l(\theta/x)$ monotona în θ , și maximum se atinge în $\hat{\theta}_n = \bar{x}_n$

în caz $\theta = 0$ dacă $\sum X_i = 0$
 $\theta = 1$ dacă $\sum X_i = n$

Ex: Determinați estimatorul prin metoda momentelor pentru acest caz

Exp: $X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2)$ cu μ și σ^2 necunoscute
 $\theta = (\theta_1, \theta_2) = (\mu, \sigma^2)$

Funcția de verosimilitate:

$$L(\mu, \sigma^2/x) = \prod_{i=1}^n f_{\theta}(x_i)$$

$$f_{\theta}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$L(\mu, \sigma^2/x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x_i-\mu}{\sigma}\right)^2}$$

$$= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i-\mu}{\sigma}\right)^2}$$

$$l(\mu, \sigma^2/x) = \log L(\mu, \sigma^2/x)$$

$$= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}$$

Avem sistemul

$$\begin{cases} \frac{\partial}{\partial \mu} l(\mu, \sigma^2/x) = 0 \\ \frac{\partial}{\partial \sigma^2} l(\mu, \sigma^2/x) = 0 \end{cases}$$

~~$$\frac{\partial}{\partial \mu} l(\mu, \sigma^2/x) = 0$$~~

$$\hat{\sigma}_m^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_m)^2$$

Prin urmare \bar{x}_m și $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_m)^2$ sunt estimatori de verosimilitate maximă.

Exp: Fie $X_1, X_2, \dots, X_n \sim f_\theta$

$$f_\theta(x) = \begin{cases} e^{-(x-\theta)}, & x \geq \theta, \theta > 0 \\ - & \end{cases}$$

Funcția de verosimilitate:

$$L(\theta/x) = \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n e^{-(x_i-\theta)} \cdot \mathbb{1}_{(\theta, +\infty)}(x_i) =$$

$$= e^{-\sum_{i=1}^n (x_i - \theta)} \prod_{i=1}^n \mathbb{1}_{(\theta, +\infty)}(x_i) =$$


$$= e^{n\theta - \sum_{i=1}^n x_i} \cdot \underbrace{\mathbb{1}_{(\theta, +\infty)}(x_1) \cdot \mathbb{1}_{(\theta, +\infty)}(x_2) \cdot \dots \cdot \mathbb{1}_{(\theta, +\infty)}(x_n)}_{= 1, x_1, x_2, \dots, x_n \geq \theta}$$

$$= \begin{cases} 1, & x_1, x_2, \dots, x_n \geq \theta \\ 0, & \text{altfel} \end{cases}$$

$$\text{Deci } L(\theta/x) = e^{n\theta - \sum_{i=1}^n x_i} \cdot \mathbb{1}_{(\min(x_i), +\infty)}(\theta)$$

Dacă $\theta > \min(x_i) \Rightarrow L(\theta/x) = 0$

$$\text{altfel } L(\theta/x) = e^{n\theta - \sum_{i=1}^n x_i}$$



Obs. că $\frac{\partial \ln L(\theta/x)}{\partial \theta} = n \neq 0$ (funcția nu e derivabilă)

Observăm că pentru $\theta < \min(x_i)$ funcția $L(\theta/x)$, cu $L(\theta/x) = e^{n\theta - \sum_{i=1}^n x_i}$ este crescătoare (în θ), deci maximum se atinge pentru $\hat{\theta}_n = \min(x_i)$

Exp: Estimatorul de verosimilitate maximă nu este unic

Fie $x_1, x_2, \dots, x_n \sim f_\theta$ cu


$$f_\theta(x) = e^{-\frac{|x-\theta|}{2}}, x \in \mathbb{R} \text{ (Rep. Laplace)}$$

$$L(\theta/x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n e^{-\frac{|x_i-\theta|}{2}} \\ = e^{-\frac{1}{2} \sum_{i=1}^n |x_i-\theta|}$$

Cum e^x crește oarecând $\Rightarrow L(\theta/x)$ este maximă atunci când $\sum_{i=1}^n |x_i - \theta|$ minim


$$\arg \max_{\theta \in \mathbb{R}} L(\theta/x) = \arg \min_{\theta \in \mathbb{R}} \sum_{i=1}^n |x_i - \theta|$$

$$\text{Fie } M(\theta) = \sum_{i=1}^n |x_i - \theta|$$



Fie y_1, y_2, \dots, y_m valori ale lui x_1, x_2, \dots, x_n ordonate crescător astfel astfel $y_1 = \min(x_i), y_m = \max(x_i)$

Dacă $y_m < \theta \leq y_{m+1}$
atunci cum $y_i \leq y_m$ pt $i \leq m$
avem $|y_i - \theta| = \theta - y_i$, iar
 $y_j \geq y_{m+1}$
 $|y_j - \theta| = y_j - \theta$



$$M(\theta) = \sum_{i=1}^n |y_i - \theta| = \sum_{i=1}^m |y_i - \theta| + \sum_{i=m+1}^n |y_i - \theta|$$


$$= \sum_{i=1}^m (\theta - y_i) + \sum_{i=m+1}^n (y_i - \theta)$$

$$\frac{d}{d\theta} M(\theta) = m - (n - m) = 2m - n$$

$$\frac{d}{d\theta} M(\theta) = 0 \Leftrightarrow m = \frac{n}{2}$$

Dacă $m < \frac{n}{2}$, $M'(\theta) < 0$, M descrescătoare

$m > \frac{n}{2}$, $M'(\theta) > 0$, M crescătoare



Dacă n este impar, $n = 2l + 1 \Rightarrow \frac{n}{2} = l + \frac{1}{2}$

și atunci pt $\theta < y_{l+1}$, $M(\theta)$ este \searrow
 $\theta > y_{l+1}$, $M(\theta)$ este \nearrow

În acest caz $\arg\min \sum_{i=1}^n |x_i - \theta| = y_{l+1}$

$$l+1 = \frac{n-1}{2} + 1 = \frac{n+1}{2}$$

Dacă n este par, $n = 2l$ atunci
 minimumul se atinge în orice punct din $[y_l, y_{l+1}]$
 Alegem mijlocul intervalului

$$\hat{\theta}_n = \frac{y_l + y_{l+1}}{2} = \frac{y_{n/2} + y_{n/2+1}}{2}$$

Finalizând, estimatorul

$$\hat{\theta}_n = \begin{cases} y_{\frac{n+1}{2}}, & n \text{ impar} \\ \frac{y_{n/2} + y_{n/2+1}}{2}, & n \text{ par} \end{cases}$$

mediana eșantionului (empirică a eșantionului)

Intervale de încredere:

Obs: Dacă până acum în problema de estimare punctuală am plecat determinat plecând de la un eșantion cu o valoare cât mai apropiată de parametrul necunoscut care a generat observația, în această secțiune ne propunem să găsim un interval de valori a.c. probabilitatea ca acest interval să conțină adevărata valoare a parametrului să fie cât mai mare.

Def: Fie $X_1, X_2, \dots, X_n \sim f_\theta, \theta \in \Theta \subseteq \mathbb{R}$, și $\alpha \in (0, 1)$, și funcțiile $A_\alpha, B_\alpha: \mathbb{R}^n \rightarrow \mathbb{R}$ ca a.c.

$$A_\alpha(x_1, \dots, x_n) \leq B_\alpha(x_1, \dots, x_n) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n$$

Intervalul $[A_\alpha(x_1, \dots, x_n), B_\alpha(x_1, \dots, x_n)]$ s.n. interval de încredere pt. θ cu coeficientul de încredere $1-\alpha$

$$P_\theta([A_\alpha(X_1, \dots, X_n), B_\alpha(X_1, \dots, X_n)] \ni \theta) \geq 1-\alpha$$

Intervalul este aleator, nu θ

Obs: În practică $\alpha = 0.05$, și atunci $1-\alpha = 0.95$

Obs: Este posibil să fim interesați de intervale unilaterale de tipul $(-\infty, B_\alpha(X_1, \dots, X_n)]$ sau $[A_\alpha(X_1, \dots, X_n), +\infty)$

$$I L^{1-d}(\theta) = [A_d(x_1, \dots, x_m), B_d(x_1, \dots, x_m)]$$

Metoda pivotului.

Def: Fie $x_1, x_2, \dots, x_m \sim \mathcal{F}_\theta$, $\theta \in \Theta \subseteq \mathbb{R}$. O funcție $g: \mathbb{R}^m \times \Theta \rightarrow \mathbb{R}$ se numește funcție pivot dacă:

- Repartiția lui $g(x_1, \dots, x_m, \theta)$ nu depinde de θ
- Pentru orice $\mu_1 \leq \mu_2$, $u_1, u_2 \in \mathbb{R}$ inecuația $\mu_1 \leq g(x_1, \dots, x_m, \theta) \leq \mu_2$ se poate rezolva în Θ conducând la soluția

$$a(x_1, \dots, x_m) \leq \theta \leq b(x_1, \dots, x_m)$$

Def: Fie $p \in (0, 1)$. Se numește cuantilă de ordin p asociată funcției de repartiție F valoarea x_p care verifică

$$x_p = F^{-1}(p) = \inf \{x \mid F(x) \geq p\}$$

Obs: Cuantila de ordin p este acea valoare pentru care $p\%$ din observații sunt mai mici și $1-p$ mai mari.

Dacă $p = \frac{1}{2}$, atunci cuantila de ordin $\frac{1}{2}$ e mediană.

$$x_{1/2} - \text{mediana } (g_2)$$

$$P(X \leq x_{1/2}) = P(X > x_{1/2}) = \frac{1}{2}$$

Dacă $p = \frac{1}{4}$ (resp. $\frac{3}{4}$), atunci cuantila de ordin $\frac{1}{4}$ se numește prima cuantila / a treia cuantilă g_1 g_3

Idea: T n estimator pt θ pt. care cunoaștem cum este repartizat (nu depinde de θ)

u_1 și u_2 cuantilele de ordin $\frac{\alpha}{2}$ și $1 - \frac{\alpha}{2}$

Intervalul de încredere va fi $[u_1, u_2]$ cu probabilitate $1 - \alpha$

Intervale de încredere pentru populații normale
 a) Int. inc. pentru media unei populații normale
 atunci când varianța este cunoscută

$$X_1, X_2, \dots, X_m \sim N(\mu, \sigma^2) \quad \begin{array}{l} \mu - \text{ necunoscut} \\ \sigma^2 - \text{ cunoscut} \end{array}$$

Am văzut că \bar{X}_m , estimatorul pentru medie

$$\bar{X}_m \sim N(\mu, \sigma^2/m) \Rightarrow \sqrt{m} \cdot \frac{\bar{X}_m - \mu}{\sigma} \sim N(0, 1)$$

Funcția $g(\underbrace{X_1, \dots, X_m}_{T_m}, \mu) = \sqrt{m} \cdot \frac{\bar{X}_m - \mu}{\sigma}$ este o fun. pivot

Ție $z_{\alpha/2}$ și $z_{1-\alpha/2}$ quantilele de ordin $\alpha/2$ și resp. $1-\alpha/2$ din $N(0, 1)$

$$P_{\mu} \left(z_{\alpha/2} \leq \sqrt{m} \cdot \frac{\bar{X}_m - \mu}{\sigma} \leq z_{1-\alpha/2} \right) = 1 - \alpha$$

$$\Leftrightarrow P_{\mu} \left(\bar{X}_m - z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{m}} \leq \mu \leq \bar{X}_m - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{m}} \right) = 1$$

$$z_{\alpha/2} = z_{1-\alpha/2} \text{ în } N$$

$$IC^{1-\alpha}(\mu) = \left[\bar{X}_m - z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{m}} ; \bar{X}_m + z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{m}} \right]$$

b) varianța necunoscută

$$X_1, \dots, X_m \sim N(\mu, \sigma^2), \quad \mu, \sigma^2 \text{ necunoscute}$$

$$T_m = \sqrt{m} \cdot \frac{\bar{X}_m - \mu}{S_m} \sim t_{m-1} \quad (t\text{-Student})$$

Funcția $g(X_1, \dots, X_m, \mu) = \sqrt{m} \cdot \frac{\bar{X}_m - \mu}{S_m}$ este o funcție pivot.

Pt. de (9.1) Ție $t_{\alpha/2}$ și $t_{1-\alpha/2}$ quantilele de ordin $\alpha/2$ și $1-\alpha/2$. Atunci

$$P_{\mu} \left(t_{\alpha/2} \leq \sqrt{m} \cdot \frac{\bar{X}_m - \mu}{S_m} \leq t_{1-\alpha/2} \right) = 1 - \alpha$$

Dim symmetric reproductive student: $t_{\alpha/2} = -t_{1-\alpha/2}$

$$IC^{1-\alpha}(\mu) = \left[\bar{X}_n - t_{1-\alpha/2} \frac{S_n}{\sqrt{n}}, \bar{X}_n + t_{1-\alpha/2} \frac{S_n}{\sqrt{n}} \right]$$

consultative

① $X \sim \mathcal{N}([0, 1])$